

Sigmoid损失用于语言-图像预训练

Xiaohua Zhai* Basil Mustafa Alexander Kolesnikov
LucasBeyer*谷歌DeepMind, 瑞士苏黎世
{xzhai, basilm, akolesnikov, lbeyer}@谷歌.com

摘要

我们提出了一种用于语言-图像预训练的简单成对 *Sigmoid* 损失 (*SigLIP*)。与使用 *softmax* 归一化的标准对比学习不同, *Sigmoid* 损失仅作用于图像-文本对, 并且不需要对两两相似度进行全局视角的归一化。*Sigmoid* 损失同时允许进一步扩大批量大小, 同时在较小的批量大小下也能表现得更好。结合锁定图像微调, 仅使用四个 *TPUv4* 芯片, 我们在两天内训练了一个 *SigLiT* 模型, 该模型达到了 84.5% 的 *ImageNet* 零样本准确率。将批量大小与损失解耦, 进一步使我们能够研究样本与配对以及负样本与正样本比率的影响。最后, 我们将批量大小推到极限, 高达一百万, 并发现增大批量大小的收益迅速递减, 而更合理的 32k 批量大小就足够了。我们在 <https://github.com/google-research/big-vision> 上发布我们的模型, 并希望我们的研究能激励进一步提升语言-图像预训练质量和效率的探索。

1. 引言

利用网络上图像-文本对的弱监督信号进行对比预训练, 正逐渐成为获取通用计算机视觉骨干网络的主流方法, 并逐步取代在大规模标注多类数据集上的预训练。其核心思想是通过配对数据, 同时学习图像和文本的对齐表示空间。开创性工作 CLIP [36] 和 ALIGN [23] 确立了大规模下该方法的可行性, 在它们成功之后, 许多大型图像-文本数据集开始以私有形式 [59, 13, 21, 49] 和公开形式 [40, 6, 15, 7, 41] 出现。

预训练此类模型的标准方法利用图像-文本对比目标。它将图像与

表1: **SigLiT与SigLIP结果**。Sigmoid损失函数具有内存效率, 支持更大的批量大小 (BS), 从而能够使用少量芯片实现语言图像预训练。使用冻结的公共B/8检查点 [42], 在LiT图像-文本数据集 [59] 上使用四块TPU-v4芯片训练一天的SigLiT模型, 在ImageNet上达到了79.7%的零样本准确率。相同设置下使用g/14检查点 [58] 训练两天, 准确率达到84.5%。使用公共解锁的B/16图像检查点 [42], 在WebLI数据集 [13], 上训练的SigLIP, 使用16块TPU-v4芯片训练三天, 实现了71.0%的零样本准确率。最后两行展示了随机初始化模型的结果。

	图像 文本		BS	#TPUv4	日	INet-0
SigLiT		B/8 L*	32 k	4	1	79.8
SigLiT		g/14 L	20 k	4	2	84.5
SigLIP		B/16 B	16 k	16	3	71.0
SigLIP		B/16 B	32 k	32	2	72.1
SigLIP		B/16 B	32 k	32	5	73.4

* 我们使用了L模型的变体, 包含12个层。

文本嵌入用于匹配 (正样本) 图像-文本对, 同时确保无关 (负样本) 图像-文本对在嵌入空间中不相似。这是通过一种批次级软最大化对比损失函数实现的, 该损失函数被应用两次, 先对所有图像、再对所有文本的成对相似度得分进行归一化。软最大化的简单实现在数值上不稳定; 通常通过对所有输入值应用软最大化之前减去最大值来使其稳定 [18], 这需要对完整批次进行另一次遍历。

在本文中, 我们提出了一种更简单的替代方案: Sigmoid损失。它不需要在完整批次上进行任何操作, 从而大大简化了分布式损失函数的实现并提高了效率。此外, 它在概念上将批量大小与任务定义解耦。我们在多种设置下比较了所提出的Sigmoid损失与标准Softmax损失。具体而言, 我们研究了基于sigmoid的损失在两种著名的

*同等贡献

图像-文本学习方法中的应用：CLIP [36] 和LiT [59]，我们分别称之为sigmoid语言图像预训练（SigLIP）和sigmoid LiT（SigLiT）。我们发现，当批量大小小于16k时，Sigmoid损失的表现显著优于Softmax损失。随着训练批次大小的增加，差距逐渐缩小。重要的是，Sigmoid损失是对称的，仅需单次传递，且典型实现所需内存少于Softmax损失。这使我们能够成功训练批量大小为一百万的SigLiT模型。然而，我们发现，随着批量大小的增加，无论是Softmax还是Sigmoid，其性能都会趋于饱和。好消息是，合理的批量大小（即32k）足以用于图像-文本预训练。这一结论同样适用于超过100种语言的多语言SigLIP训练。

在表1中，我们展示了需要中等数量TPUv4芯片进行训练的图像-文本预训练配置。SigLiT效率惊人，仅需四块芯片在一天内即可在ImageNet上达到79.7%的零样本准确率。SigLIP要求更高的从头训练则需32块TPUv4芯片，在5天内达到73.4%的零样本准确率。这与先前的工作（如FLIP [30]和CLIP [36]）相比更具优势，后者在256个TPUv3核心上分别需要大约5天和10天。当在SigLIP中对预训练的视觉骨干网络进行微调时（在表1中表示为该方式），我们发现，在预训练骨干网络上禁用权重衰减会带来更好的结果（详情见图4）。我们希望我们的工作能为让新兴的语言-图像预训练领域更易普及铺平道路。

2. 相关工作

基于 Sigmoid 损失的对比学习。先前有一项工作针对无监督降维任务提出了类似的 Sigmoid 损失 [19]；在对比性图像-文本学习领域，绝大多数工作依赖于基于 Softmax 的 InfoNCE 损失，该损失由 [46] 推广开来。在监督分类中，Sigmoid 损失已被证明比 Softmax 损失略为有效且更稳健 [3, 51]。

对比语言-图像预训练 自CLIP [36] 和ALIGN [23] 将软最大化对比学习 [60, 46, 10, 24] 应用于大规模图像-文本数据集以来已变得流行。两种模型在零样本迁移任务（包括分类和检索）上表现非常出色。后续工作表明，对比预训练模型为微调 [53, 16]、线性回归 [23]、目标检测 [31]、语义分割 [33]和视频任务 [57] 生成了良好的表征。

生成式语言-图像预训练除了基于Softmax的对比预训练，还有多种替代方案被提出。GIT [49]、SimVLM [50]，和LEMON [21] 成功地使用生成式文本解码器对模型进行预训练

算法1 Sigmoid损失伪实现。

```
1 # 图像_嵌入 : 图像模型嵌入 [n, dim]
2 # txt_emb : 文本模型嵌入 [n, dim]
3 # t_prime, b : 可学习温度和偏置
4 # n : 小批量大小
5
6 t = exp(t_prime)
7 zimg = l2_normalize(img_emb)
8 ztxt = l2_normalize(txt_emb)
9 logits = 点积(z图像, z文本.T) * t + b
10 标签 = 2 * eye(n) - ones(n) # -1 对角线为1
11 l = -sum(log-S型(标签 * logits)) / n
```

，而CoCa [56] 将这样的解码器添加到判别式的CLIP/ALIGN框架中，从而将两种方法的优点和缺点结合到一个非常强大的模型中。BLIP [28] 进一步提出了CapFilt，它利用生成式解码器生成更优质的描述，并利用模型的判别部分来过滤配对。语言-图像预训练是一个非常活跃的领域，相关的综述 [8] 很快就会过时。

高效语言-图像预训练 另一方面，很少有研究尝试让语言图像预训练更高效。LiT [59]和FLIP [30]是值得注意的尝试：前者需要预训练且锁定的主干网络，后者则通过随机丢弃视觉令牌来牺牲质量。BASIC [35]和LAION [52] 关注批次规模的扩展，但分别仅达到16k和160k，这需要数百个芯片，并且前者还混合了大型私有分类数据集 [35, 55]。最近的LION优化器 [12] 声称能降低训练成本以达到相近的质量。


3. 方法

在本节中，我们首先回顾广泛使用的基于软最大化的对比损失函数。然后，我们介绍成对Sigmoid损失函数并讨论其高效实现。

给定一批 $B = \{(I_1, T_1), (I_2, T_2) \dots\}$ 图像-文本对，对比学习目标鼓励匹配对 (I_i, T_i) 的嵌入彼此对齐，同时将不匹配对 $(I_i, T_{j \neq i})$ 的嵌入推开。出于实用目的，假设对于所有图像 i ，与另一图像 j 相关的文本与 i 无关，反之亦然。这一假设通常带有噪声且不完美。

3.1. 语言图像预训练的Softmax损失函数

当使用Softmax损失函数来形式化这一目标时，图像模型 $f(\cdot)$ 和文本模型 $g(\cdot)$ 会被训练以



(a) 初始状态下，每个设备持有4个图像和4个文本表示。(b) 每个设备为其表示计算损失函数组件（高亮部分），其中包含正样本。每个设备需要查看来自其他设备的表示才能计算完整的损失。(c) 各设备间的文本被交换，因此设备1现在拥有 $I_{1:4}$ 和 $T_{5:8}$ 等。新损失函数被计算并与之前的累计。(d) 此过程重复直至每个图像与文本对都完成交互，例如设备1已获得 $I_{1:4}$ 和 $T_{1:12}$ 的损失函数。最终的跨设备求和将所有结果汇总在一起。

图1：高效的损失实现通过一个包含3个设备和全局批大小为12的模拟设置进行演示。过程中没有全收集操作，且在任何时间点，只有亮黄色方块（大小 4×4 ）在内存中实例化。

最小化以下目标函数：

$$-\frac{1}{2|\mathcal{B}|} \sum_{i=1}^{|\mathcal{B}|} \left(\log \frac{e^{t\mathbf{x}_i \cdot \mathbf{y}_i}}{\sum_{j=1}^{|\mathcal{B}|} e^{t\mathbf{x}_i \cdot \mathbf{y}_j}} + \log \frac{e^{t\mathbf{x}_i \cdot \mathbf{y}_i}}{\sum_{j=1}^{|\mathcal{B}|} e^{t\mathbf{x}_j \cdot \mathbf{y}_i}} \right)$$

其中 $\mathbf{x}_i = \frac{f(I_i)}{\|f(I_i)\|_2}$ 和 $\mathbf{y}_i = \frac{g(T_i)}{\|g(T_i)\|_2}$ 。在本文中，我们采用视觉变换器架构 [17] 用于图像，以及变换器架构 [47] 用于文本。需要注意的是，由于 Softmax 损失的不对称性，归一化操作需独立进行两次：一次跨图像，一次跨文本 [36]。标量 t 被参数化为 $\exp(t')$ ，其中 t' 是一个全局可自由学习的参数。

3.2. Sigmoid 损失用于语言-图像预训练

作为基于 softmax 的对比损失的替代方案，我们提出了一种更简单的方案，无需计算全局归一化因子。基于 Sigmoid 的损失独立处理每一对图像-文本对，有效地将学习问题转化为标准二分类任务，作用于所有配对组合的数据集，其中匹配对 (I_i, T_i) 为正样本，所有其他对 $(I_i, T_{j \neq i})$ 为负样本。其定义如下：

$$-\frac{1}{|\mathcal{B}|} \sum_{i=1}^{|\mathcal{B}|} \sum_{j=1}^{|\mathcal{B}|} \log \frac{1}{1 + e^{z_{ij}(-t\mathbf{x}_i \cdot \mathbf{y}_j + b)}} \quad \mathcal{L}_{ij}$$

其中 z_{ij} 是针对给定图像和文本输入的标签，如果成对则为 1，否则为 -1。初始

化时，大量负样本带来的严重不平衡主导了损失函数，导致初始优化步长过大，试图纠正这种偏置。为缓解此问题，我们引入一个额外的可学习偏置项 b ，类似于温度 t 。我们将 t' 和 b 初始化为 $\log_{10}$ 和 -10 。这确保了训练初始阶段大致接近先前分布，无需大规模过度修正。算法 1 给出了所提出的用于语言图像预训练的 Sigmoid 损失的伪代码实现。

3.3. 高效的“分块”实现

对比训练通常采用数据并行。当数据分散在 D 各设备上时，计算损失需要借助昂贵的全收集操作来汇聚所有嵌入 [59]，更重要的是，这还需要实例化一个内存密集型的 $|\mathcal{B}| \times |\mathcal{B}|$ 两两相似度矩阵。

然而，Sigmoid 损失特别适合实现一种内存高效、快速且数值稳定的方案，从而同时缓解这两个问题。将每台设备的批量大小记为 $b = \frac{|\mathcal{B}|}{D}$ ，损失函数可重新表述为：

$$-\frac{1}{|\mathcal{B}|} \sum_{d_i=1}^D \sum_{d_j=1}^D \sum_{i=bd_i}^{b(d_i+1)} \sum_{j=bd_j}^{b(d_j+1)} \mathcal{L}_{ij}$$

A: $\forall$ 设备 d_i B: 交换负样本跨设备 C: 每设备 loss

全部本地正样本 负样本来自下一个设备

对于 Sigmoid 损失来说，这尤其简单，因为每一对都是损失中的一个独立项。图 1 展示了这一点




图2：预训练批量大小的影响。左图：SigLiT模型结果，训练了180亿个已见样本。在小批量大小下，Sigmoid损失函数显著优于Softmax损失函数，而在较大批量大小时性能相近。我们成功训练了批量大小高达一百万的SigLiT模型。然而，Sigmoid和Softmax损失函数的性能均在批量大小约32k时趋于饱和。中图：SigLIP结果，训练了90亿个已见样本。Sigmoid损失函数和Softmax损失函数均在合理的批量大小时达到饱和，而Sigmoid损失函数的峰值出现更早，且略优于Softmax损失函数的峰值。非常大的批量大小对两种损失函数都有损害。右图：mSigLIP结果，训练了300亿个已见样本。在使用超过100种语言的多语言设置下，32k的批量大小出人意料地足够，且超过该规模进行扩展反而会损害在36种语言跨模态检索任务上的性能。

方法。简而言之，我们首先计算与正样本对对应的损失分量，然后计算负样本对对应的损失分量。然后我们在各设备间对表征进行排列，使每个设备从相邻设备（下一次迭代的求和 **B**）获取负样本。然后针对这一块（求和 **C**）计算损失。每个设备独立执行此操作，使得每个设备针对其本地批次 b 计算损失。接着，只需将所有设备上的损失相加（求和 **A**）。单独的集体排列（用于求和 **B**）速度很快（实际上 D 集体排列通常比两次 D 设备间的全收集更快），并且任意时刻的内存成本从 $|B|^2$ 降低到 b^2 （用于求和 **C**）。通常， b 是恒定的，因为扩展 $|B|$ 是通过增加加速器数量实现的。由于朴素损失计算与批量大小呈二次方关系，它迅速成为扩展的瓶颈。这种分块方法使得在相对较少的设备上，能够使用超过100万的批量大小进行训练。

4. 实验结果

在本节中，我们评估了所提出的 SigLiT 和 SigLIP 模型在多种批量大小下的表现。我们讨论了在使用少量加速器芯片的情况下，通过 SigLiT 和 SigLIP 配方所能实现的效果。我们还简要探讨了批量大小对多语言语言图像预训练的影响。我们消融研究了大批次稳定化修改的重要性以及引入的学习偏置项，并呈现了一项关于 Sigmoid 损失中正负样本对比比例影响的研究。最后，

我们探索了 SigLIP 的数据噪声鲁棒性。

为了验证我们的模型，我们报告了在 ImageNet 数据集上的零样本迁移结果 [14]，以及在 XM3600 数据集上跨36种语言的零样本检索结果 [44]。我们默认对所有实验使用 ScalingViT-Adafactor 优化器 [58]。

4.1. SigLiT：将批量大小扩展至极限

遵循 [59] 的方法，我们使用相同的 ViT-g 视觉模型预计算图像嵌入，并在 LiT 图像-文本数据集上从头训练一个基础规模的文本塔，采用相同的超参数 [59]。

我们针对从 512 到 1 M 的广泛批量大小范围进行了研究，展示了批量大小对对比学习的影响。结果如图2（左）所示。当批量大小小于 16 k 时，Sigmoid 损失以较大优势优于 Softmax 损失。随着批量大小的增加，我们观察到 Softmax 损失迅速追赶，并且在批量大小足够大时，其性能可能略低于 Sigmoid 损失。总体而言，鉴于其简洁性、计算节省以及直接高效的内存实现，我们建议在大量批量大小下也使用 SigLIP 方案。

学界普遍认为对比学习得益于大批量大小，而现有研究大多止步于 64k 批次大小 [59, 35, 10]。我们成功训练了一个一百万批次大小的 SigLiT 模型，以探索对比学习的极限。出乎意料的是，性能在 32k 批次大小处饱和，进一步扩大批量大小仅带来微小提升，模型峰值出现在




图 3: 不同训练时长下 SigLiT ImageNet 零样本迁移的结果。大批量大小能显著提升性能, 但需要足够长的训练时长才能充分发挥效果; 若训练时长较短, 则过大的批量大小会导致梯度更新步数过少。

256k 批次大小。我们最佳的 SigLiT 使用 B 尺寸文本模型在 ImageNet 上实现了 84.7% 的零样本迁移准确率, 而原始 LiT 论文中采用大 10 倍的 g 尺寸文本模型取得了略高的 85.2% 分数。图 3 展示了不同批量大小下训练时长的影响。结果表明, 当训练时间足够长时, 大 262k 批量大小显著优于较小 8k 批量大小。需要注意的是, 对于短训练时长, 大批量大小会导致绝对更新步数减少, 因此需要更多时间才能进入加速阶段。

4.2. SigLIP: Sigmoid 损失对语言-图像预训练有益

我们在 WebLI 数据集上预训练 SigLIP 模型 [13], 仅使用英文图像和文本对。我们使用 CLIP (WebLI) 表示在 WebLI 上使用标准 Softmax 损失预训练的 CLIP 基线模型。我们采用中等规模的模型: B/16 ViT 用于图像嵌入, B 尺寸变换器用于文本嵌入。输入图像被调整为 224×224 分辨率。文本由 32k 词汇量的 SentencePiece 分词器 [27] 在英文 C4 数据集上训练 [37], 最多保留 16 个文本令牌。图 2 中间部分显示 SigLIP 结果, 在小于 32k 的批量大小下, SigLIP 优于 CLIP (WebLI) 基线。在规模的另一端, Sigmoid 损失的内存效率支持了更大的批量大小。例如, 使用四个 TPU-v4 芯片, 基座 SigLIP 可容纳 4096 的批量大小, 而对应的 CLIP 模型仅能容纳 2048。这两个优势共同表明, Sigmoid 损失在固定资源下进行语言图像预训练具有显著优势, 这将在第 4.5 节中讨论。

	16 k	32 k	64 k	128k	240k
INet-0	71.6	73.2	73.2	73.2	73.1
XM 平均	34.8	34.9	34.4	33.6	32.7
XM 德	54.7	54.8	55.4	54.3	54.7
XM 英	46.5	46.2	46.5	46.6	46.6
XM hi	9.1	8.5	7.9	8.1	7.3
XM ru	50.1	49.9	49.7	48.6	49.3
XM zh	30.7	32.5	32.0	30.6	23.7

表 2: 在不同批量大小下预训练的多语言 SigLIP 结果, 已处理 300 亿个可见示例。我们报告了在 ImageNet (INet-0) 上的零样本迁移结果, 以及在跨模态 3600 数据集 (XM) 上跨 36 种语言的文本到图像检索平均结果。包含 36 种语言的完整表格见附录。

随着批量大小的增加, Sigmoid 损失与 Softmax 损失之间的差距逐渐缩小。SigLIP 在批量大小为 32k 时表现最佳, 而 Softmax 损失需要 98k 才能达到最佳性能, 且仍未能超越基于 S 型函数的变体。进一步扩展, 更大的批量大小 (如 307k) 对两种损失均产生负面影响。

4.3. mSigLIP: 多语言预训练

我们通过保留 WebLI 数据集的所有 100 种语言进一步扩展训练数据 [13]。使用多语言数据时, 通常需要采用更大的国际化词汇表。我们首先验证了两种分词器的影响: 一个包含 32k 词元的小型多语言词汇表 [37], 和一个包含 250k 词元的大型多语言词汇表 [54]。我们训练了 B 级 ViT 和文本模型, 共处理 900 M 个可见示例, 观察到使用更大词汇表时性能提升略高于 1%。

然而, 对于非常大的词汇量, 词元嵌入会变得巨大。按照标准设置, 我们需要存储一个 $N \times W$ 词元嵌入查找表来训练多语言模型, 其中 N 是上述词汇量, W 是文本模型的嵌入维度。为了节省内存, 我们提出使用“瓶颈式”词元嵌入。我们使用 $N \times K$ 嵌入矩阵和额外的 $K \times W$ 投影, 其中瓶颈 K 远小于 W 。

在我们的实验中, 我们观察到, 使用带有瓶颈的大规模多语言词汇表可以像使用小型多语言词汇表一样高效地扩展。具体来说, 在 $K = 96$ 大小的瓶颈下, 为基础架构启用大小为 $W = 768$ 的瓶颈, 与使用完整的 250k 词汇表相比, 我们在 ImageNet 零样本迁移上仅看到约半个百分点的质量下降。




图4：上图：使用预训练编码器的SigLIP快速攀升。然而，仅在预训练编码器权重上禁用权重衰减即可实现稳定行为，并取得良好的ImageNet零样本迁移结果。下图：ImageNet 10-shot迁移结果，对预训练权重进行衰减会导致预训练模型视觉表征质量下降。禁用权重衰减可使曲线趋于平缓。

借助内存优化，我们针对各种批量大小训练了mSigLIP模型，总共处理了300亿个样本。表2和图2（右侧图）展示了结果。我们原本预期较大的批量大小能改善多语言预训练，因为模型会在同一个小批量中从同一语言看到更多作为困难负样本的样本。然而，我们并未观察到批量大小超过32k时有明显的改进。32k的批量大小对于多语言设置也足够。在XM3600跨模态检索任务上，我们发现超过32k批量大小会导致平均结果变差，而在ImageNet零样本迁移上则保持平稳。mSigLIP在XM3600文本到图像检索任务上树立了新的最先进水平，且仅使用基础规模模型。我们的最佳结果是34.9%，比之前报告的28.5%高出超过6% [13]，后者使用的是标准LiT模型 [59]，并且采用了更大的40亿参数ViT-e模型。我们将在第4.6节进一步扩展mSigLIP的训练规模。

4.4. 使用四块TPU-v4芯片的SigLiT

对于许多实践者来说，重要的问题通常是“在有限资源下能训练什么？”在本节中，我们仅使用四块TPU-v4芯片探索SigLiT模型的使用，因为内存高效的Sigmoid损失适用于这一应用场景。




图5：Adam与AdaFactor的影响 β_2 。随着批次大小的增加，我们观察到训练不稳定性更加频繁。这种在损失曲线（上图）中显现的不稳定性，是由梯度范数（中图）的尖峰导致参数更新（下图）幅度过大引起的。降低 β_2 动量可稳定训练。偶尔仍会出现梯度尖峰（例如在20亿步时），但不会破坏训练过程。

我们采用与第4.1节相同的设置。使用公开的ViT-AugReg-B/8 [42] 模型作为冻结的()视觉塔，并预计算嵌入以加速训练 [59]。文本模型是一个大型Transformer，但其深度仅为12层（而非24层）。它使用LION [12] 优化器进行训练，采用解耦权重衰减 1×10^{-7} ，学习率经过6500步线性预热至峰值 1×10^{-4} ，随后余弦衰减至0。我们总共训练65000步，批量大小为32k——这使训练时间不到一天。表1展示了在四块芯片上训练一天的结果，达到了79.7%的零样本ImageNet分类准确率；在此有限资源条件下极具竞争力。使用ViT-g/14 [58] 模型作为视觉塔和大型文本塔，我们可以在四块芯片上以20k批量大小训练107k步，耗时不到两天。这进一步将零样本ImageNet分类准确率提升至84.5%。

4.5. 使用少量TPU-v4芯片的SigLIP

从头训练一个CLIP模型通常资源消耗巨大，而使用SigLIP则能以更少的芯片来容纳更大的训练批次大小。在本节中，我们将探索利用预训练权重高效训练SigLIP模型的方法。我们使用预训练权重来初始化图像模型以加速预训练，这一方法最初




图6: 批次组成的影响。我们通过掩码负样本来模拟各种批次组成, 掩码方式包括随机掩码、仅保留最困难的负样本或仅保留最简单的负样本。无掩码时, 批次中每个正样本对应16k个负样本 (1:16k); 当应用最强掩码时 (1:1.6), 小批次几乎达到平衡。在一种设置中, 我们通过显著延长训练时间匹配所见的总体本对数量。我们观察了ImageNet零样本分数、学习到的偏置的最终值、以及正负样本对的平均对数几率。总体而言, 不平衡似乎并无害处, 但找到一种高效的负样本挖掘方式可能是有益的。

在 [59] 中讨论过。我们采用公开且无锁的 ViT-AugReg-B/16 [42] 模型来初始化视觉塔, 并在与 SigLIP 相同的 WebLI 英语数据上进行微调。在所有的实验中, 我们对预训练图像塔应用 0.1 的学习率乘数, 使其适用于微调。

图 4 展示了解锁微调结果, 并与从头随机初始化的基线进行了对比。我们使用了 16 个 TPU-v4 芯片, 并以 16k 的批量大小训练, 共处理了 24 亿个样本。我们发现微调设置开箱即用效果不佳; 这与先前的工作一致 [59], 其中微调图像模型会降低视觉表征质量。这一点可以从 ImageNet 10-shot 线性分类中看出, 在图 4 中, 微调后的设置仅比从头训练的基线略好。

我们假设对预训练权重应用的默认权重衰减会降低其有效性。受 [17, 58, 25], 中不使用权重衰减的微调方案启发, 我们也建议在 SigLIP 训练中禁用对预训练权重的权重衰减。因此, 权重衰减仅应用于文本模型中随机初始化的权重。这一简单修改显著提升了 SigLIP 的效果。图 4 显示, 采用我们改进的方案, SigLIP 在使用 16k 批大小、16 个芯片训练三天后, 在 ImageNet 上达到了 71% 的零样本准确率。我们还在表 1 下半部分展示了从头训练的结果: 仅用 32 个 TPUv4 芯片训练两天, SigLIP 就达到了 72.1% 的零样本准确率。与 [30] 中报道的 CLIP (约 2500 TPUv3 天达到 72.6%) 相比, 这显著降低了训练成本。

4.6. 扩展 SigLIP 与 mSigLIP

在本节中, 我们通过“过度训练”模型来扩展 SigLIP [45, 1]。我们使用 ViT-B、ViT-L 或 So-400m [1] 作为视觉编码器, 并搭配相同规模的文本编码器 (分别为 B、L 和 So-400m), 结果展示在表 3 中。按照第 4.2 节描述的方案, 我们以 32k 的批大小训练两个模型处理 400 亿个示例, 但使用 $(256/16)^2 = 256$ 个图像块和 64 个文本令牌 (而非 16 个)。为了获得不同分辨率的 SigLIP 模型, 我们在目标分辨率下额外训练 50 亿个示例, 学习率降低 100 倍且不使用权重衰减。在表 3 中, 我们报告了在 ImageNet [14], ObjectNet [2], ImageNet-v2 [39], ImageNetRealL [3], 上的零样本分类结果, 以及在 MSCOCO [11] 上的零样本图像到文本 (I→T) 检索和文本到图像 (I→T) 检索结果。

我们以相同的方式扩展了多语言 mSigLIP ViT-B 模型。我们报告了在 XM3600 基准上跨越 36 种语言的图文检索结果 [44]。扩展后的 mSigLIP ViT-B 模型在基础模型中取得了最先进的成绩: 图像检索召回率 @1 为 42.6%, 文本检索召回率 @1 为 54.1%。这稍逊于大型模型 [48] 所取得的 42.96% 图像检索召回率 @1。详细结果见附录表 9 和图 8, 标记为 *32k。

4.7. 稳定大批量训练

随着我们转向大批量大小, 使用 Transformer 进行语言-图像预训练变得越来越不稳定, 即使在使用中等规模模型 (如基础规模) 时也是如此。造成这些不稳定的原因在于

方法	图像编码器		验证集	ImageNet-1k			COCO R@1	
	ViT尺寸	# 图像块		v2	ReaL	ObjectNet	我 → T	T → 我
CLIP	B	196	68.3	61.9	-	55.3	52.4	33.1
OpenCLIP	B	196	70.2	62.3	-	56.0	59.4	42.3
EVA-CLIP	B	196	74.7	67.0	-	62.3	58.7	42.2
SigLIP	B	196	76.2	69.6	82.8	70.7	64.4	47.2
SigLIP	B	256	76.7	70.0	83.1	71.3	65.1	47.4
SigLIP	B	576	78.6	72.1	84.5	73.8	67.5	49.7
SigLIP	B	1024	79.2	73.0	84.9	74.7	67.6	50.4
CLIP	L	256	75.5	69.0	-	69.9	56.3	36.5
OpenCLIP	L	256	74.0	61.1	-	66.4	62.1	46.1
CLIPA-v2	L	256	79.7	72.8	-	71.1	64.1	46.3
EVA-CLIP	L	256	79.8	72.9	-	75.3	63.7	47.5
SigLIP	L	256	80.5	74.2	85.9	77.9	69.5	51.1
CLIP	L	576	76.6	72.0	-	70.9	57.9	37.1
CLIPA-v2	L	576	80.3	73.5	-	73.1	65.5	47.2
EVA-CLIP	L	576	80.4	73.8	-	78.4	64.1	47.9
SigLIP	L	576	82.1	75.9	87.0	81.0	70.6	52.7
OpenCLIP	G (20亿)	256	80.1	73.6	-	73.0	67.3	51.4
CLIPA-v2	H (6.3亿)	576	81.8	75.6	-	77.4	67.2	49.2
EVA-CLIP	E (50亿)	256	82.0	75.7	-	79.6	68.8	51.1
SigLIP	SO (400M)	729	83.2	77.2	87.5	82.9	70.2	52.0

表 3：与其他公开发布模型的对比。我们的 SigLIP 模型在所有现有模型（如 Open-CLIP [22] 和 CLIP [36],）之上，在零样本分类和检索任务上均取得了显著优势。与同期发布的 EVA-CLIP [43] 和 CLIPA-v2 [29], 相比，我们的 SigLIP-L 在低分辨率和高分辨率场景下均表现更优。特别值得注意的是，采用形状优化的 400M 参数 ViT [1] 架构，其性能超越了所有规模显著更大的模型。我们公开发布了我们的模型：https://github.com/google-research/big_vision。

梯度范数出现大幅尖峰，这会导致权重发生大幅度变化，可能破坏训练过程的稳定性，如图5所示。我们观察到，将 β_2 中的Adam和AdaFactor参数从默认值0.999降低至0.95（如 [20, 9]所建议），足以稳定训练。直观而言，这有助于更快地从梯度尖峰中恢复。我们选择在所有实验中设置 $\beta_2 = 0.95$ 。

4.8. Sigmoid 损失中的负样本比例

将视角从软最大化的“选择正确的类别”转换为S型函数的“评价这对样本”时，出现的一个问题是正样本对与负样本对之间的不平衡。对于批量大小 $|B|$ ，该批次包含 $|B|$ 个正样本对，但包含 $|B|^2 - |B|$ 个负样本。在16k的适中批量大小下，仅16k个正样本就对应高达2.68亿个负样本。同时，由于Sigmoid损失函数可分解为每个样本损失之和，我们能够通过受控实验来研究小批次组成及样本分布的影响。

在SigLiT设置中，我们以16k的批量大小进行9亿步的实验，并通过掩码操作（即忽略）足够多的负样本，以达到目标“正样本：负样本”比例，从而改变批次组成。掩码操作采用以下方式：

- **随机**：随机选择要遮蔽的负样本对。
- **困难**：保留最困难的负样本对（损失最高）。
- **容易**：保留最容易的负样本对（损失最低）。
- **困难 + 匹配的总训练对数量**：在固定步数训练过程中进行掩码示例，确实会减少训练期间看到的对总数。因此，在匹配对的设置中，我们根据掩码比例增加训练步数，以保持看到的对数量不变。

图6展示了各种<masking>掩码</masking>策略的效果。
 <Random>随机</Random>移除<negatives>负样本</negatives>以重新平衡确实会降低性能。保留最简单的样本完全无效，而保留最
 <Hard>困难</Hard>的<negatives>负样本</negatives>几乎能




图7: **Sigmoid**训练增强了对数据噪声的鲁棒性。标题显示了所应用的损坏类型，x轴显示了其应用的频率。随着损坏严重程度的增加，使用Sigmoid损失在36亿样本上训练的M尺度模型，其性能仍优于相应的Softmax基线。

维持质量，这表明，正如预期的那样， $\langle \text{negatives} \rangle$ 负样本 $\langle \text{negatives} \rangle$ 方面的学习很大程度上来自于更 $\langle \text{Hard} \rangle$ 困难 $\langle \text{Hard} \rangle$ 的样本。这一结论通过稍微提升的性能得到了进一步证实：在最 $\langle \text{Hard} \rangle$ 困难 $\langle \text{Hard} \rangle$ 的样本上训练更长时间以匹配所见的总样本对。

我们还考察了训练结束时学习到的偏置值，以及在這些设置下正负样本的平均对数几率值，发现结果基本符合预期：随着负样本数量的减少，偏置和logit值总体上变得更正。有趣的是，当使用更多困难负样本对进行训练时，正样本对的平均logit值基本保持平稳。

本项研究证实：（1）不平衡似乎不是主要担忧的原因，同时（2）提出一种包含更多负样本的高效方法虽前景可期，但并非易事。

4.9. Sigmoid损失中的偏置项

我们消融了损失函数中的偏置项，采用8k批量大小的基础架构，在SigLIP配置下训练了9亿样本。零样本迁移结果报告于ImageNet [14], Oxford-iiit宠物 [34] 和CIFAR100 [26]上。表4展示了Sigmoid损失中带偏置项和不带偏置项的结果。

表 4: **偏置 (b) 和温度 (t')** 初始化。结果基于基础架构、8k 批量大小，训练了 9 亿个样本。启用偏置项 b 并配合-10初始化，可持续改进结果。

b	t'	INet-0	Pet-0	C100-0
n/a	log 10	62.0	81.8	59.9
-10	log 10	63.0	82.4	61.0
-10	log 1	61.0	80.0	60.4
0	log 10	61.7	79.9	59.0
0	log 1	53.7	73.2	53.8

启用带有 -10 初始化的偏置项能持续提升所有任务的性能。这是因为偏置项确保训练从接近先验的位置开始，防止在早期优化中出现过度修正。相比之下，随机选择的偏置项初始化（如表4中的0初始化）无法解决过度修正问题，导致结果显著变差。这一效应在使用较小的温度 t' 初始化时尤为明显。我们将偏置和温度初始化默认设置为 $b = -10$ 和 $t' = \log 10$ （即 $t = 10$ ），并作为所有实验的默认配置。

4.10. 标签噪声鲁棒性

先前的研究表明，在分类模型中使用Sigmoid损失函数可以提高对标签噪声的鲁棒性 [3]。这一特性在应对著名的大规模图像-文本数据集普遍存在的高噪声特性时尤为有用。为了研究SigLIP的这一特性，我们使用M/16图像模型和M文本模型在批量大小为16384的情况下进行训练，共训练36亿个已见样本。我们通过以下方法之一对训练数据进行破坏处理：

- **图像**：以概率 p ，将该图像替换为均匀随机噪声。
- **文本**：以概率 p ，将分词文本替换为新的随机采样词元序列，序列长度（随机采样）不超过某个值。
- **批次对齐**：随机打乱批次中 $p\%$ 的顺序。
- **图像与文本**：分别以概率 p 同时应用两者。
- **图像、文本与批次**：在 (4) 的基础上，额外随机打乱 p 部分的对齐关系。

改变损坏可能性的结果如图7所示。使用Sigmoid损失训练的模型对所有类型的添加噪声具有更强的鲁棒性。

5. 结论

我们对两个使用Sigmoid损失的语言-图像预训练实例（SigLiT和SigLiP）进行了研究。结果表明，Sigmoid损失的性能优于Softmax基线，尤其是在训练批次大小较小时。该损失函数还具有更高的内存效率，从而可以在不增加资源的情况下使用更大的训练批次大小。我们对对比学习中的批次大小进行了深入调查。令人惊讶的是，我们发现相对适中的32k批量大小就能达到近乎最优的性能。我们还进行了进一步研究，以更好地理解Sigmoid损失中引入的偏置项、对数据噪声的鲁棒性以及Sigmoid损失中正负样本对比比例的影响。我们希望这项工作能够促进在资源有限条件下的语言-图像预训练研究。

致谢。 我们感谢 Daniel Keysers、Ilya Tolstikhin、Olivier Bousquet 和 Michael Tschannen 对本论文提出的宝贵反馈和讨论。我们感谢 Joan Puigcerver、Josip Djolonga 和 Black Hechtman 关于分块对比损失高效实现的讨论。我们感谢 Kaiming He 和 Xinlei Chen 讨论 β_2 如何稳定训练。我们还要感谢 Ross Wightman 指出本论文初版伪代码中的一个错误，以及 Boris Dayma 和 Krzysztof Maziarczyk 指出第二和第三版中的笔误，这些错误使得 t 与 t' 令人困惑。我们感谢 Google DeepMind 团队提供了支持性的研究环境。我们使用 `bigvision` 代码库 [5, 4] 进行本项目中的所有实验。

参考文献

- [1] Ibrahim Alabdulmohsin, Xiaohua Zhai, Alexander Kolesnikov, 和 Lucas Beyer. 将 ViT 调整为理想形态: 计算最优模型设计的缩放定律. 收录于 NeurIPS, 2023. 7, 8, 17[2] Andrei Barbu, David Mayo, Julian Alverio, William Luo, Christopher Wang, Dan Gutfreund, Josh Tenenbaum, 和 Boris Katz. ObjectNet: 一个用于推动物体识别模型极限的大规模偏差控制数据集. 收录于 NeurIPS, 2019. 7, 17[3] Lucas Beyer, Olivier J. Hénaff, Alexander Kolesnikov, Xiaohua Zhai, 和 Aaron van den Oord. ImageNet 我们已经搞定了吗? CoRR, abs/2006.07159, 2020. 2, 7, 9, 17[4] Lucas Beyer, Xiaohua Zhai, 和 Alexander Kolesnikov. ImageNet-1k 的更优纯 ViT 基线, 2022. 10, 17[5] Lucas Beyer, Xiaohua Zhai, 和 Alexander Kolesnikov. Big vision. https://github.com/google-research/big_vision, 2022. 10, 17[6] Minwoo Byeon, Beomhee Park, Haechon Kim, Sungjun Lee, Woonhyuk Baek, 和 Saehoon Kim. Coyo-700m: 图像-文本对数据集. <https://github.com/kakaobrain/coyo-dataset>, 2022. 1[7] Soravit Changpinyo, Piyush Sharma, Nan Ding, 和 Radu Soricut. Conceptual 12M: 推动网络规模图像-文本预训练以识别长尾视觉概念. 收录于 CVPR, 2021. 1[8] Feilong Chen, Duzhen Zhang, Minglun Han, Xiu-Yi Chen, Jing Shi, Shuang Xu, 和 Bo Xu. VLP: 视觉-语言预训练综述. Int. J. Autom. Comput., 20 56, 2023 1 38 2 () : - . [9] Mark Chen, Alec Radford, Rewon Child, Jeffrey Wu, Heewoo Jun, David Luan, 和 Ilya Sutskever. 从像素进行生成式预训练. 收录于第37届国际机器学习大会会议录, ICML 2020, 2020年7月13-18日, 虚拟会议, 第119卷, 机器学习研究会议录, 页码 1691–1703. PMLR, 2020. 8[10] Ting Chen, Simon Kornblith, Mohammad Norouzi, 和 Geoffrey E. Hinton. 视觉表征对比学习的一个简单框架. 收录于 ICML, 2020. 2, 4[11] Xinlei Chen, Hao Fang, Tsung-Yi Lin, Ramakrishna Vedantam, Saurabh Gupta, Piotr Dollár, 和 C. Lawrence Zitnick. Microsoft COCO 标题: 数据收集与评估服务器. CoRR, abs/1504.00325, 2015. 7, 17[12] Xiangning Chen, Chen Liang, Da Huang, Esteban Real, Kaiyuan Wang, Yao Liu, Hieu Pham, Xuanyi Dong, Thang Luong, Cho-Jui Hsieh, Yifeng Lu, 和 Quoc V. Le. 优化算法的符号发现, 2023. 2, 6[13] Xi Chen, Xiao Wang, Soravit Changpinyo, A. J. Piergiovanni, Piotr Padlewski, Daniel Salz, Sebastian Goodman, Adam Grycner, Basil Mustafa, Lucas Beyer, Alexander Kolesnikov, Joan Puigcerver, Nan Ding, Keran Rong, Hassan Akbari, Gaurav Mishra, Linting Xue, Ashish Thapliyal, James Bradbury, Weicheng Kuo, Mojtaba Seyedhosseini, Chao Jia, Burcu Karagol Ayan, Carlos Riquelme, Andreas Steiner, Anelia Angelova, Xiaohua Zhai, Neil Houlsby, 和 Radu Soricut. Pali: 一种联合缩放的多语言语言-图像模型. CoRR, abs/2209.06794, 2022. 1, 5, 6, 17[14] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, 和 Li Fei-Fei. ImageNet: 一个大规模层次化图像数据库. 发表于 CVPR, 2009. 4, 7, 9, 17[15] Karan Desai, Gaurav Kaul, Zubin Aysola, 和 Justin Johnson. RedCaps: 由人民创建、为人民服务的网络策展图像-文本数据. 载于 Joaquin Vanschoren 和 Sai-Kit Yeung 编辑, 《神经信息处理系统数据集与基准轨道会议论文集1, NeurIPS 数据集与基准2021, 2021年12月, 线上》, 2021. 1[16] Xiaoyi Dong, Jianmin Bao, Ting Zhang, Dongdong Chen, Shuyang Gu, Weiming Zhang, Lu Yuan, Dong Chen, Fang Wen, 和 Nenghai Yu. CLIP 本身就是一个强微调器: 使用 ViT-B 和 ViT-L 在 ImageNet 上达到 85.7% 和 88.0% 的 top-1 准确率. CoRR, abs/2212.06138, 2022. 2[17] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, 和 Neil Houlsby. 一张图像胜过 16×16 个词: 用于图像识别的规模化 Transformer. 发表于 ICLR, 2021. 3, 7, 17[18] Ian Goodfellow, Yoshua Bengio, 和 Aaron Courville. 深度学习. MIT 出版社, 2016. <http://www.deeplearningbook.org>. 1[19] Raia Hadsell, Sumit Chopra, 和 Yann LeCun. 通过学习不变映射进行降维. 发表于 CVPR, 第2卷, 2006. 2[20] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, 和 Ross B. Girshick. 掩码自编码器是可扩展视觉学习器. 载于 IEEE/CVF 计算机视觉与模式识别会议, CVPR 2022, 美国路易斯安那州新奥尔良, 2022年6月18-24日, 第15979–15988页. IEEE, 2022. 8 [21] Xiaowei Hu, Zhe Gan, Jianfeng Wang, Zhengyuan Yang, Zicheng Liu, Yumao Lu, 和 Lijuan Wang. 扩展用于图像描述的视觉-语言预训练. CoRR, abs/2111.12233, 2021. 1, 2 [22] Gabriel Ilharco, Mitchell Wortsman, Nicholas Carlini, Rohan Taori, Achal Dave, Vaishaal Shankar, Hongseok Namkoong, John Miller, Hannaneh Hajishirzi, Ali Farhadi, 和 Ludwig Schmidt. OpenCLIP. Zenodo, 2021. 8 [23] Chao Jia, Yinfei Yang, Ye Xia, Yi-Ting Chen, Zarana Parekh, Hieu Pham, Quoc V. Le, Yun-Hsuan Sung, Zhen Li, 和 Tom Duerig. 通过带噪文本监督扩展视觉和视觉-语言表示学习. 发表于 ICML, 2021. 1, 2[24] Prannay Khosla, Piotr Teterwak, Chen Wang, Aaron Sarna, Yonglong Tian, Phillip Isola, Aaron Maschiot, Ce Liu, 和 Dilip Krishnan. 有监督对比学习. 载于 Hugo Larochelle, Marc’Aurelio Ranzato, Raia Hadsell, Maria-Florina Balcan, 和 Hsuan-Tien Lin 编辑, 《神经信息处理系统进展33: 年度神经信息处理系统会议2020, NeurIPS 2020, 2020年12月6-12日, 线上》, 2020. 2[25] Alexander Kolesnikov, Lucas Beyer, Xiaohua Zhai, Joan Puigcerver, Jessica Yung, Sylvain Gelly, 和 Neil Houlsby.

大迁移学习 (BiT) : 通用视觉表示学习。发表于ECCV, 2020. 7[26] Alex Krizhevsky. 从微小图像中学习多层特征。技术报告, 多伦多大学, 2009. 9[27] Taku Kudo and John Richardson. SentencePiece: 一种用于神经文本处理的简单且语言无关的子词分词器和去分词器。发表于EMNLP, 2018. 5, 14[28] Junnan Li, Dongxu Li, Caiming Xiong, and Steven C. H. Hoi. BLIP: 用于统一视觉-语言理解与生成的引导语言-图像预训练。载于Kamalika Chaudhuri, Stefanie Jegelka, Le Song, Csaba Szepesvári, Gang Niu, and Sivan Sabato编辑, 《国际机器学习大会, ICML 2022, 2022年7月17-23日, 美国马里兰州巴尔的摩》, 第162卷《机器学习研究会议论文集》, 第12888-12900页。PMLR, 2022. 2[29] Xianhang Li, Zeyu Wang, and Cihang Xie. Clipa-v2: 在\$10,000预算内将CLIP训练扩展到81.1%的零样本ImageNet准确率; 额外\$4,000解锁81.8%准确率。CoRR, abs/2306.15658, 2023. 8[30] Yanghao Li, Haoqi Fan, Ronghang Hu, Christoph Feichtenhofer, and Kaiming He. 通过掩码扩展语言-图像预训练。CoRR, abs/2212.00794, 2022. 2, 7. . .

[31] Matthias Minderer, Alexey A. Gritsenko, Austin Stone, Maxim Neumann, Dirk Weissenborn, Alexey Dosovitskiy, Aravindh Mahendran, Anurag Arnab, Mostafa Dehghani, Zhuoran Shen, Xiao Wang, Xiaohua Zhai, Thomas Kipf, and Neil Houlsby. 简单开放词汇目标检测。载于Shai Avidan, Gabriel J. Brostow, Moustapha Cissé, Giovanni Maria Farinella, and Tal Hassner编辑, 《计算机视觉-ECCV 2022 - 第17届欧洲会议, 以色列特拉维夫, 2022年10月23-27日, 会议论文集, 第十部分》, 第13670卷《计算机科学讲义》, 第728-755页。施普林格, 2022. 2[32] Margaret Mitchell, Simone Wu, Andrew Zaldivar, Parker Barnes, Lucy Vasserman, Ben Hutchinson, Elena Spitzer, Inioluwa Deborah Raji, and Timnit Gebru. 用于模型报告的模式卡。载于danah boyd和Jamie H. Morgenstern编辑, 《公平、问责与透明度会议论文集, FAT* 2019, 美国佐治亚州亚特兰大, 2019年1月29-31日》, 第220-229页。ACM, 2019. 17[33] Jishnu Mukhoti, Tsung-Yu Lin, Omid Poursaeed, Rui Wang, Ashish Shah, Philip H. S. Torr, and Ser-Nam Lim. 基于补丁对齐对比学习的开放词汇语义分割, 2022. 2. Omkar M. Parkhi, Andrea

[34] Vedaldi, Andrew Zisserman, and C. V. Jawahar. 猫狗数据集。发表于IEEE计算机视觉与模式识别会议, 2012. 9[35] Hieu Pham, Zihang Dai, Golnaz Ghiasi, Hanxiao Liu, Adams Wei Yu, Minh-Thang Luong, Mingxing Tan, and Quoc V. Le. 用于零样本迁移学习的联合缩放。CoRR, abs/2111.10050, 2021. 2, 4[36] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. 从自然语言监督中学习可迁移视觉模型。发表于ICML, 2021. 1, 2, 3, 8

[37] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, 以及 Peter J. Liu. 探索基于统一文本到文本变换器的迁移学习极限。《arXiv e-prints》, 2019年。第5页, 第14页[38] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, 以及 Peter J. Liu. 探索基于统一文本到文本变换器的迁移学习极限。《J. Mach. Learn. Res.》, 21:140:1-140:67, 2020年。第17页[39] Benjamin Recht, Rebecca Roelofs, Ludwig Schmidt, 以及 Vaishal Shankar. ImageNet分类器能否泛化到ImageNet? 收录于《ICML》, 2019年。第7页, 第17页[40] Christoph Schuhmann, Romain Beaumont, Richard Vencu, Cade Gordon, Ross Wightman, Mehdi Cherti, Theo Coombes, Aarush Katta, Clayton Mullis, Mitchell Wortsman, Patrick Schramowski, Srivatsa Kundurthy, Katherine Crowson, Ludwig Schmidt, Robert Kaczmarczyk, 以及 Jenia Jitsev. LAION-5B: 用于训练下一代图像文本模型的开放大规模数据集。《CoRR》, abs/2210.08402, 2022年1. . [41] Krishna Srinivasan, Karthik Raman, Jiecao Chen, Michael Bendersky, 以及 Marc Najork. WIT: 用于多模态多语言机器学习的基于维基百科的图像文本数据集。《CoRR》, abs/2103.01913, 2021年。第1页[42] Andreas Steiner, Alexander Kolesnikov, Xiaohua Zhai, Ross Wightman, Jakob Uszkoreit, 以及 Lucas Beyer. 如何训练你的ViT? 视觉变换器中的数据、增强与正则化。《CoRR》, abs/2106.10270, 2021年。第1页, 第6页, 第7页[43] Quan Sun, Yuxin Fang, Ledell Wu, Xinlong Wang, 以及 Yue Cao. EVA-CLIP: 大规模CLIP训练的改进技术。《CoRR》, abs/2303.15389, 2023年。第8页[44] Ashish V. Thapliyal, Jordi Pont-Tuset, Xi Chen, 以及 Radu Soricut. Crossmodal-3600: 一个大规模多语言多模态评估数据集。收录于 Yoav Goldberg, Zornitsa Kozareva, 以及 Yue Zhang 编辑的《Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing, EMNLP 2022, Abu Dhabi, United Arab Emirates, December 7-11, 2022》, 第715-729页。计算语言学协会, 2022年。第4页, 第7页, 第17页[45] Hugo Touvron, Thibaut Lavril, Gautier Izacard, Xavier Martinet, Marie-Anne Lachaux, Timothée Lacroix, Baptiste Rozière, Naman Goyal, Eric Hambro, Faisal Azhar, Aurélien Rodriguez, Armand Joulin, Edouard Grave, 以及 Guillaume Lample. Llama: 开放高效的基础语言模型。《CoRR》, abs/2302.13971, 2023年。第7页[46] Aaron van den Oord, Yazhe Li, 以及 Oriol Vinyals. 基于对比预测编码的表征学习。《CoRR》, abs/1807.03748, 2018年。第2页[47] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, 以及 Illia Polosukhin. 注意力机制即一切。收录于《NeurIPS》, 2017年。第3页, 第17页[48] Alexander Visheratin. 预算内训练高性能多语言图像检索模型Nllb-clip, 2023年。第7页[49] Jianfeng Wang, Zhengyuan Yang, Xiaowei Hu, Linjie Li, Kevin Lin, Zhe Gan, Zicheng Liu, Ce Liu, 以及 Lijuan Wang. GIT: 面向视觉和语言的生成式图像到文本变换器。《CoRR》, abs/2205.14100, 2022年。第1页, 第2页

[50] Zirui Wang, Jiahui Yu, Adams Wei Yu, Zihang Dai, Yulia Tsvetkov, 以及 Yuan Cao. Simvln: 基于弱监督的简单视觉语言模型预训练。收录于《The Tenth International Conference on Learning Representations, ICLR 2022, Virtual Event, April 25-29, 2022》。OpenReview.net, 2022年。第2页[51] Ross Wightman, Hugo Touvron, 以及 Hervé Jégou. Resnet strikes back: timm中的改进训练流程。《CoRR》, abs/2110.00476, 2021年。第2页[52] Mitchell Wortsman. 使用OpenCLIP达到80%零样本准确率: 基于LAION-2B训练的ViT-G/14。h
t
t
p
s://
w
e
b.
arc
hive.org/web/20230127012732/https://laion.ai/blog/giant-openclip/。第2页[53] Mitchell Wortsman, Gabriel Ilharco, Jong Wook Kim, Mike Li, Simon Kornblith, Rebecca Roelofs, Raphael Gontijo Lopes, Hannaneh Hajishirzi, Ali Farhadi, Hongseok Namkoong, 以及 Ludwig Schmidt. 零样本模型的鲁棒微调。收录于《IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2022, New Orleans, LA, USA, June 18-24, 2022》, 第7949–7961页。IEEE, 2022年。第2页[54] Linting Xue, Noah Constant, Adam Roberts, Mihir Kale, Rami Al-Rfou, Aditya Siddhant, Aditya Barua, 以及 Colin Raffel. mT5: 一个大规模多语言预训练文本到文本变换器。收录于《NAACL-HLT》, 2021年。第5页, 第17页[55] Jianwei Yang, Chunyuan Li, Pengchuan Zhang, Bin Xiao, Ce Liu, Lu Yuan, 以及 Jianfeng Gao. 图像-文本-标签空间中的统一对比学习。收录于《IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2022, New Orleans, LA, USA, June 18-24, 2022》, 第19141–19151页。IEEE, 2022年。第2页[56] Jiahui Yu, Zirui Wang, Vijay Vasudevan, Legg Yeung, Mojtaba Seyedhosseini, 以及 Yonghui Wu. CoCa: 对比解码器是图像文本基础模型。《CoRR》, abs/2205.01917, 2022年。第2页[57] Lu Yuan, Dongdong Chen, Yi-Ling Chen, Noel Codella, Xiyang Dai, Jianfeng Gao, Houdong Hu, Xuedong Huang, Boxin Li, Chunyuan Li, Ce Liu, Mengchen Liu, Zicheng Liu, Yumao Lu, Yu Shi, Lijuan Wang, Jianfeng Wang, Bin Xiao, Zhen Xiao, Jianwei Yang, Michael Zeng, Luowei Zhou, 以及 Pengchuan Zhang. Florence: 计算机视觉的新基础模型。《CoRR》, abs/2111.11432, 2021年。第2页[58] Xiaohua Zhai, Alexander Kolesnikov, Neil Houlsby, 以及 Lucas Beyer. 缩放视觉变换器。《CVPR》, 2022年。第1页, 第4页, 第6页, 第7页, 第14页[59] Xiaohua Zhai, Xiao Wang, Basil Mustafa, Andreas Steiner, Daniel Keysers, Alexander Kolesnikov, 以及 Lucas Beyer. Lit: 基于锁定图像文本调优的零样本迁移。收录于《IEEE/CVF Conference on Computer Vision and Pattern Recognition, CVPR 2022, New Orleans, LA, USA, June 18-24, 2022》, 第18102–18112页。IEEE, 2022年。第1页, 第2页, 第3页, 第4页, 第6页, 第7页, 第14页[60] Yuhao Zhang, Hang Jiang, Yasuhide Miura, Christopher D. Manning, 以及 Curtis P. Langlotz. 基于配对图像和文本的医学视觉表征对比学习。收录于 Zachary C. Lipton, Rajesh Ranganath, Mark P. Sendak, Michael W. Sjöding, 以及 Serena Yeung 编辑的《Proceedings of the Machine Learning for Healthcare Conference》,

MLHC 2022, 2022年8月5-6日, 美国北卡罗来纳州达勒姆, 第182卷机器学习研究会议论文集, 第2–25页。PMLR, 2022年。

2

A. SigLiT的更多结果

在第4.1节中，我们使用来自 [59]的ViT-g视觉模型对图像采用相同的预计算嵌入。仅应用调整大小增强，将分辨率固定为 288×288 。我们使用ScalingViT-Adafactor优化器 [58]训练一个标准尺寸的文本塔，参数设置包括 $\beta_1 = 0.9$ 和 $\beta_2 = 0.95$ 。学习率设为0.001，采用线性预热调度，在前200M个训练样本上进行预热，之后使用余弦学习率调度将学习率衰减至零。所有实验的权重衰减均设为0.0001。文本由在英文C4数据集 [27] 上训练的32k词汇量的句子片段分词器 [37]进行分词，并最多保留16个文本令牌。表8 展示了在不同训练样本数量和批量大小下的结果，对比了Sigmoid损失函数和Softmax损失函数基线。

为了在4块芯片上一天内训练SigLiT（请参阅第4.4节），我们使用了LION优化器，其峰值学习率为 1×10^{-4} 且权重衰减为 1×10^{-7} 。学习率在6.5千步内线性升至峰值，然后在剩余的58.5千步中按余弦衰减至零。

B. SigLIP的更多结果

在表5中，我们展示了SigLIP Base在多个训练样本数量下的更多结果：分别是30亿个样本和90亿个样本。

批量大小	3 B		9 B	
	S型	软最大化	S型	软最大化
512	51.5	47.7	-	-
1 k	57.3	53.2	-	-
2 k	62.1	59.3	-	-
4 k	65.3	63.8	68.4	66.6
8 k	68.6	66.6	70.6	69.4
16 k	-	-	72.3	71.7
32 k	69.9	69.9	73.4	72.9
98 k	69.5	69.7	73.0	73.2
307 k	-	-	71.6	72.6

表5: SigLIP在ImageNet基准测试上的零样本准确率 (%)。同时展示了基于Sigmoid损失函数和基于Softmax损失函数的基线结果。实验在多种训练样本数量（30亿、90亿）和训练批次大小（从512到307k）下进行。当使用90亿样本训练时，基于Sigmoid损失函数的峰值在32k时出现，早于基于Softmax损失函数在98k时出现的峰值。结合Sigmoid损失函数在内存效率上的优势，这使得我们能够用更少的加速器训练出最佳的语言-图像模型。

BS	默认	Best	最佳学习率	最佳权重衰减
8 k	70.1	70.1	0.001	0.0001
16 k	70.0	70.0	0.001	0.0001
32 k	68.2	69.0	0.0003	0.00003

表6: 不同批量大小下的默认超参数，这些参数在扫描中要么表现最佳，要么接近最佳。报告了在ImageNet上的零样本准确率。BS=批量大小，LR=学习率，WD=权重衰减。

C. SigLIP结果的鲁棒性

不同批次大小的超参数。Sigmoid损失函数无需针对不同批次大小调整超参数。例如，在SigLIP和SigLiT配置中，我们在从512到1024k的广泛批次大小范围内，仅使用了默认的0.001学习率和0.0001权重衰减。我们进一步在从头训练的SigLIP设置中，针对3个批次大小（在30亿已见样本上）对9个超参数进行了扫描：学习率 {0.0003、0.001、0.003} × 权重衰减 {0.00003、0.0001、0.0003} × 批次大小 {8 16k、32k}。我们在表6 中观察到，默认的学习率/权重衰减要么是最优的，要么接近最优。

标准差。我们使用推荐的32k批次大小和30亿已见样本，重复五次SigLIP训练。我们在表7中报告了平均值和标准差。五次运行的标准差对于Sigmoid和软最大化都非常小。

替代优化器。我们使用AdamW优化器重复相同的实验五次，得到的结果和标准差与表7中报告的结果非常相似。我们测试了线性学习率调度器代替默认的余弦学习率调度器，其准确率达到69.9%。

D. mSigLIP的更多结果

我们在图8 和表9中，展示了mSigLIP Base在Crossmodal-3600数据集上所有36种语言的跨模态检索结果。

Loss	优化器	结果 (%)
软最大化	ViT-Adafactor	69.9 ± 0.1
S型	ViT-Adafactor	70.1 ± 0.2
S型	AdamW	70.3 ± 0.1

表 7: 五次重复实验的均值与标准差。报告为在ImageNet上的零样本准确率。

批量大小	450 M		900 M		3 B		18 B	
	S型	软最大化	S型	软最大化	S型	软最大化	S型	软最大化
512	72.5	69.5	75.0	72.8	77.2	74.6	-	-
1 k	75.5	73.6	77.2	76.0	79.6	77.9	-	-
2 k	77.1	76.3	79.3	78.1	81.3	80.1	82.2	81.2
4 k	79.2	78.3	80.8	79.8	82.4	81.2	83.0	82.0
8 k	80.8	79.7	82.0	81.0	83.1	82.6	83.6	83.1
16 k	81.2	81.2	82.7	82.1	83.8	83.5	84.2	84.1
32 k	81.9	81.4	83.1	82.7	84.2	84.0	84.6	84.4
64 k	81.6	81.6	83.0	82.8	84.3	84.1	84.7	84.4
128k	80.5	80.0	83.1	83.2	84.2	84.4	84.7	84.6
256 k	72.8	72.2	82.1	81.7	84.3	84.2	84.7	84.6
1024 k	-	-	-	-	-	-	84.7	-

表8: **SigLiT**在ImageNet基准测试上的零样本准确率(%)。同时展示了Sigmoid损失函数和Softmax损失函数基线。我们在多种训练样本数量(4.5亿、9亿、30亿、180亿)和训练批次大小(从512到100万)上进行了大量实验。




图8: **Crossmodal-3600**所有36种语言上的图像到文本和文本到图像零样本检索召回率@1结果。上方: 图像到文本。下方: 文本到图像。颜色代表批次大小。*32k代表第4.6节中描述的放大结果。

E. 标签噪声实验

所有模型均采用M/16图像塔和M文本塔。它们从随机初始化开始训练, 处理了36亿个样本, 批量大小为16384。使用余弦学习率调度, 并采用初始线性预热, 预热步数占总步数的10%, 峰值学习率为0.001。

语言	图像到文本						文本到图像					
	16 k	32 k	64 k	128k	240k	*32k	16 k	32 k	64 k	128k	240k	*32k
ar	52.4	51.3	51.5	51.5	51.1	59.7	37.6	37.4	37.1	36.3	36.0	44.9
bn	11.4	10.8	10.4	10.3	9.9	30.1	5.5	6.2	4.9	5.1	4.4	20.0
cs	54.1	53.7	53.7	52.8	51.8	58.9	41.8	41.6	41.5	39.9	39.4	47.0
da	62.7	62.4	62.0	60.4	59.3	68.4	47.0	47.0	45.6	43.0	43.5	52.9
de	70.3	71.4	71.2	71.1	70.2	79.7	54.7	54.8	55.4	54.3	54.7	65.3
el	36.9	35.8	35.1	34.5	33.8	47.4	22.4	22.8	22.0	21.3	20.8	32.2
en	50.1	50.5	50.2	49.9	50.7	52.5	46.5	46.2	46.5	46.6	46.6	47.6
es	64.7	64.9	67.2	65.3	65.6	66.3	54.8	55.0	55.5	54.5	55.2	57.0
fa	57.0	57.8	56.1	55.3	54.6	66.2	39.6	40.2	38.4	38.4	38.3	50.0
fi	54.9	54.1	53.8	51.7	51.7	59.1	37.7	37.1	36.4	34.0	34.5	44.0
fil	23.2	22.8	22.9	21.4	21.2	29.2	12.8	12.9	12.4	12.2	11.3	20.4
fr	65.7	66.9	67.0	66.1	66.5	71.2	55.9	57.1	55.5	54.4	54.3	61.8
hi	19.9	18.8	19.9	19.5	17.4	32.2	9.1	8.5	7.9	8.1	7.3	17.3
hr	52.7	53.0	53.0	49.9	49.6	62.6	38.2	37.1	36.4	35.2	34.3	47.2
hu	57.0	57.1	56.3	54.8	53.0	62.9	41.4	40.2	40.2	38.6	38.2	51.2
id	64.8	67.1	66.6	65.4	64.7	73.7	48.5	49.4	49.5	47.8	47.3	60.5
it	65.9	66.4	67.1	65.2	66.1	72.3	55.5	56.4	55.8	54.8	54.1	62.3
iw	48.4	47.9	47.7	46.1	45.2	62.2	31.8	31.8	31.9	30.1	30.1	48.0
ja	46.4	45.9	42.9	43.7	30.2	55.1	31.0	31.3	29.2	28.9	18.5	42.3
ko	50.8	49.5	49.4	50.2	46.8	61.4	34.4	34.7	33.2	33.1	31.5	45.9
mi	0.4	0.4	0.6	0.6	0.4	0.3	0.2	0.2	0.2	0.2	0.2	0.3
nl	59.6	60.4	58.9	58.3	57.9	63.6	48.9	49.5	48.9	48.4	47.9	53.6
no	61.4	62.4	62.0	60.9	59.9	65.3	45.3	46.2	45.0	43.5	43.7	50.0
pl	62.2	62.0	62.0	61.1	60.5	67.1	48.8	47.4	48.7	46.8	46.7	56.7
pt	63.1	63.6	64.9	64.3	63.2	65.4	52.4	52.3	52.3	51.9	52.4	57.3
quz	6.8	6.4	6.4	6.6	6.7	6.8	2.7	2.6	2.7	2.7	2.8	2.9
ro	52.1	51.4	51.0	50.6	49.3	61.0	37.2	35.6	34.3	34.5	32.5	49.3
ru	62.2	63.6	63.1	62.7	63.1	68.4	50.1	49.9	49.7	48.6	49.3	59.9
sv	62.3	63.5	63.5	63.1	61.2	67.7	47.9	48.2	47.6	46.2	46.2	52.0
sw	14.8	14.4	14.3	14.2	13.8	17.4	7.8	7.2	7.1	6.9	6.3	10.7
te	1.2	1.2	1.2	1.7	1.1	8.4	0.4	0.3	0.3	0.5	0.3	4.3
th	36.1	35.8	35.6	35.6	28.3	39.0	21.6	23.1	22.2	21.6	16.8	24.6
tr	53.1	54.5	53.7	52.9	51.2	62.0	37.3	37.4	37.8	37.0	36.1	48.1
uk	51.4	51.5	51.2	49.9	49.2	61.2	34.5	33.2	33.8	32.5	32.4	48.3
vi	59.6	59.8	59.5	58.5	58.8	68.4	41.4	41.9	41.9	40.6	40.3	52.3
zh	44.1	45.7	44.1	41.9	36.1	53.9	30.7	32.5	32.0	30.6	23.7	46.8
avg	47.2	47.4	47.1	46.3	45.0	54.1	34.8	34.9	34.4	33.6	32.7	42.6

表9: 基于mSigLIP模型, 在不同的批量大小下训练, 总样本数为300亿时, 在Crossmodal-3600全部36种语言上的图像到文本(文本检索)和文本到图像(图像检索)的零样本召回率@1结果, *32k表示第4.6节所述的放大结果。

F. 模型卡

我们对模型的描述如下 [32]。

- **模型架构：**该模型采用本文所述的Sigmoid损失对比预训练技术进行训练。该对比模型包含两个编码器，即视觉变换器编码器 [17]和语言Transformer编码器 [47]。视觉编码器和语言编码器的大小始终相同，包括ViT-B、ViT-L和SoViT-400M [1]。
- **输入：**视觉编码器以图像 ($224 \times 224 \times 3$, $256 \times 256 \times 3$, $384 \times 384 \times 3$, $512 \times 512 \times 3$) 作为输入。文本编码器以裁剪至前64个标记的分词文本 [38, 54]作为输入。
- **输出：**视觉编码器和文本编码器均输出 d 维特征向量，其中对于ViT-B、ViT-L和SoViT-400M, d 分别为768、1024和1152。
- **预期用途：**这些模型专为多模态研究目的而设计。模型可用于零样本图像分类和零样本图像-文本检索，通过比较两者的特征向量实现。我们提供了纯英文和多语言训练的模型，以鼓励研究这一选择所带来的影响。
- **训练数据：**该对比模型使用WebLI数据集进行从头训练。SigLIP模型在WebLI数据集的子集上进行预训练，该子集经过过滤，主要包含英文内容。mSigLIP模型则在未经过语言过滤的WebLI数据集上进行预训练。
- **评估数据：**零样本分类在ImageNet [14], ImageNet v2 [39], ImageNet ReaL [3], 和 ObjectNet [2]上进行。零样本检索在COCO [11]以及多语言XM3600数据集 [44]上进行。
- **硬件与软件：**这些模型在big vision代码库 [5, 4]中开发，并在谷歌云TPU上进行训练。